

Distribuição Multinomial: Propriedades, Inferência e Exemplos

André F. B. Menezes

Department of Statistics, Universidade Estadual de Maringá, PR, Brasil

3 de Abril de 2018

- 1 Introdução
- 2 Verossimilhança
- 3 Exemplos

- ▶ Agresti, A., 1990. **Categorical Data Analysis**. Wiley: New York.
- ▶ Agresti, A., 2007. **An Introduction to Categorical Data Analysis**. John Wiley & Sons, Inc: New Jersey.
- ▶ Bishop, Y. M. M., Fienberg, S. E., Holland, P.W., 1975. **Discrete Multivariate Analysis: Theory and Practice**. Cambridge, MA: The MIT Press.
- ▶ Davis, C. S., Jones, M. P., 1992. **Maximum likelihood estimation: for the Multinomial distribution**. Teaching Statistics 14 (3), 9–11.
- ▶ Gelman, A., Carlin, J. B., Stern, H. S., Rubin, D. B., 2004. **Bayesian Data Analysis**. Chapman & Hall/CRC: New York.
- ▶ Johnson, N. L., Kotz, S., Balakrishnan, N., 1996. **Discrete multivariate distributions**. Wiley: New York.

Definição

Considere uma série de n ensaios independentes, em que cada um dos quais apenas um dos k eventos mutuamente exclusivos E_1, E_2, \dots, E_k pode ser observado, e na qual a probabilidade de ocorrência do evento E_k é igual a p_k (com $p_1 + p_2 + \dots + p_k = 1$). Sejam N_1, N_2, \dots, N_k variáveis aleatórias denotando o número de ocorrências dos eventos E_1, E_2, \dots, E_k , respectivamente, nos n ensaios, com $\sum_{i=1}^k N_i = n$. Então a distribuição conjunta de N_1, N_2, \dots, N_k é dada por

$$\Pr [N_1 = n_1, \dots, N_k = n_k] = n! \prod_{i=1}^k \left(\frac{p_i^{n_i}}{n_i!} \right), \quad (1)$$

em que n_1, \dots, n_k são inteiros não negativos satisfazendo $\sum_{i=1}^k n_i = n$.

Definição

- ▶ A função massa de probabilidade conjunta apresentada em (1) é denominada na literatura de distribuição Multinomial, com parâmetros $(n; p_1, p_2, \dots, p_k)$;
- ▶ Os parâmetros p_i , $i = 1, \dots, k$, são chamados de probabilidades das células e n é chamado de índice;
- ▶ A distribuição Binomial é um caso espacial quando existem $k = 2$ categorias/eventos. Além disso, pode-se notar que a distribuição marginal dos N_i , $i = 1, \dots, k$, é Binomial com parâmetros (n, p_i) ;
- ▶ Portanto, a distribuição Multinomial pode ser considerada uma generalização multivariada da distribuição Binomial.

- ▶ Johnson et al. (1996) apontam que a distribuição Multinomial pode surgir em diversos contextos.
- ▶ Se X_1, X_2, \dots, X_k são variáveis aleatórias com distribuição de Poisson com média $\lambda_1, \lambda_2, \dots, \lambda_k$, respectivamente, então a distribuição condicional conjunta de X_1, X_2, \dots, X_k dado $\sum_{i=1}^k X_i = n$ é Multinomial com parâmetros $(n; \pi_1, \pi_2, \dots, \pi_k)$ em que

$$\pi_i = \frac{\lambda_i}{\lambda_1 + \lambda_2 + \dots + \lambda_k}, \quad i = 1, \dots, k.$$

Os principais momentos da distribuição Multinomial são dados por

$$\mathbb{E}(N_i) = n p_i, \quad \text{Var}(N_i) = n p_i (1 - p_i),$$

$$\text{Cov}(N_i, N_j) = -n p_i p_j, \quad \text{Corr}(N_i, N_j) = -\sqrt{\frac{p_i p_j}{(1 - p_i)(1 - p_j)}}, \quad i \neq j$$

A matriz de variância-covariância da distribuição Multinomial pode ser escrita como

$$V = n \left(\text{diag}(\mathbf{p}) - \mathbf{p} \mathbf{p}^\top \right), \quad (2)$$

em que $\mathbf{p} = (p_1, \dots, p_k)$ e $^\top$ denota o operador transposto.

Observando uma amostra aleatória $\mathbf{n} = (n_1, \dots, n_k)$ da distribuição Multinomial com $\sum_{i=1}^n n_i = n$, então os estimadores de máxima verossimilhança, $\hat{\mathbf{p}} = (\hat{p}_1, \hat{p}_2, \dots, \hat{p}_k)$ de $\mathbf{p} = (p_1, p_2, \dots, p_k)$, são obtidos maximizando a função de log-verossimilhança, cuja expressão é dada por

$$\ell = \ell(\mathbf{p} \mid \mathbf{n}) = \log n! - \sum_{i=1}^k \log n_i! + \sum_{i=1}^k n_i \log p_i. \quad (3)$$

- ▶ A restrição $\sum_{i=1}^k p_i = 1$ pode ser incorporada utilizando os multiplicadores de Lagrange (ver, por exemplo, Bishop et al., 1975, p. 446).
- ▶ Alternativamente, a redundância nos parâmetros pode ser eliminada tratando ℓ como uma função de p_1, p_2, \dots, p_{k-1} como em Agresti (1990) e Davis e Jones (1992).

Inferência Clássica

Diferenciando (3) com respeito aos parâmetros têm-se

$$\frac{\partial \ell}{\partial p_i} = \frac{n_i}{p_i} - \frac{n_k}{1 - \sum_{i=1}^{k-1} p_i} = \frac{n_i}{p_i} - \frac{n_k}{p_k}. \quad (4)$$

Igualando $\frac{\partial \ell}{\partial p_i}$ a zero obtemos

$$n_i = \frac{n_k}{p_k} p_i. \quad (5)$$

Somando ambos os lados de (5) em $i = 1, \dots, k$, obtemos que $\hat{p}_k = \frac{n_k}{n}$.
De (5) temos então que

$$\hat{p}_i = \frac{n_i}{n_k} \hat{p}_k = \frac{n_i}{n_k} \frac{n_k}{n} = \frac{n_i}{n}, \quad (6)$$

para $i = 1, \dots, k - 1$.

- Considere a hipótese nula $\mathcal{H}_0 : p_j = p_{j0}, j = 1, \dots, k$ em que $\sum_{j=1}^k p_{j0} = 1$.
- Quando \mathcal{H}_0 é verdadeira, os valores esperados de $\{n_j\}$, denominadas frequências esperadas, são $\mu_j = n p_{j0}, j = 1, \dots, k$. Pearson em 1900 propôs a seguinte estatística de teste

$$\chi^2 = \sum_{j=1}^k \frac{(n_j - \mu_j)^2}{\mu_j}. \quad (7)$$

Estatística da razão de verossimilhanças

- Sob H_0 a verossimilhança é maximizada quando $\hat{p}_j = p_{j0}$. No caso geral, ela é maximizada quando $\hat{p}_j = n_j/n$. A razão de verossimilhanças é igual a

$$\Lambda = \frac{\prod_{j=1}^k (p_{j0})^{n_j}}{\prod_{j=1}^k (n_j/n)^{n_j}}. \quad (8)$$

- Assim, a estatística da razão de verossimilhança, denotada por S_{LR} , é

$$S_{LR} = -2 \log \Lambda = 2 \sum_{j=1}^k n_j \log \left(\frac{n_j}{n p_{j0}} \right). \quad (9)$$

Inferência Bayesiana

- ▶ Alternativamente, a inferência sob os parâmetros da distribuição Multinomial pode ser realizada sob o enfoque Bayesiano.
- ▶ A distribuição a priori conjugada para \mathbf{p} é a versão multivariada da distribuição Beta denominada de distribuição Dirichlet, cuja densidade é dada por

$$\pi(\mathbf{p}) = \frac{\Gamma\left(\sum_{i=1}^k \alpha_i\right)}{\prod_{i=1}^k \Gamma(\alpha_i)} \prod_{i=1}^k p_i^{\alpha_i-1}, \quad (10)$$

em que $\alpha_i > 0$, $p_i > 0$ com $\sum_{i=1}^k p_i = 1$.

- ▶ O hiperparâmetro α_i pode ser interpretado como uma contagem virtual para o valor i , antes de observar o n_i . Grandes valores para α_i corresponde a um forte conhecimento a priori sobre a distribuição, ao passo que pequenos valores de α_i corresponde a ignorância.
- ▶ A distribuição Dirichlet tem média e variância expressas, respectivamente, por

$$\mathbb{E}(p_i) = \frac{\alpha_i}{\alpha_0} \quad \text{e} \quad \text{Var}(p_i) = \frac{\alpha_i (\alpha_0 - \alpha_i)}{\alpha_0^2 (\alpha_0 + 1)}, \quad (11)$$

em que $\alpha_0 = \sum_{i=1}^k \alpha_i$.

- A distribuição a posteriori é proporcional a

$$\pi(\mathbf{p} \mid \mathbf{n}) \propto \pi(\mathbf{p}) L(\mathbf{p} \mid \mathbf{n}) \quad (12)$$

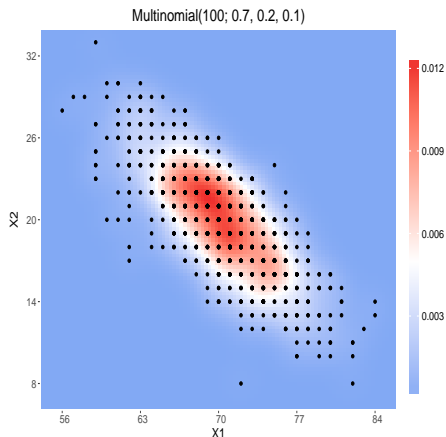
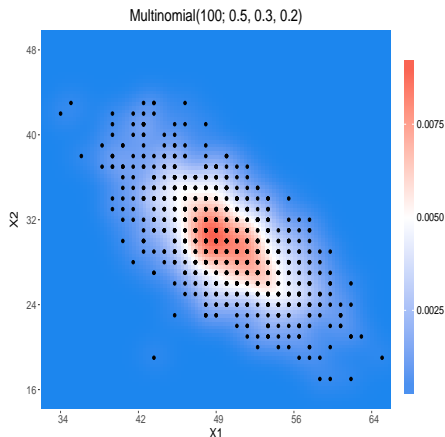
Substituindo as expressões pode-se mostrar que

$$\pi(\mathbf{p} \mid \mathbf{n}) = \frac{\Gamma\left(\sum_{i=1}^k n_i + \alpha_i\right)}{\prod_{i=1}^k \Gamma(n_i + \alpha_i)} \prod_{i=1}^k p_i^{n_i + \alpha_i - 1} \sim \mathcal{D}(n_i + \alpha_i), \quad (13)$$

isto é, a densidade a posteriori tem distribuição Dirichlet com parâmetros $n_i + \alpha_i$.

Dados simulados

- Utilizando o software R simulamos 1000 amostras pseudos aleatórias da distribuição Multinomial supondo três categorias (X_1 , X_2 e X_3) com parâmetros $n = 100$, $\mathbf{p} = (0.5, 0.3, 0.2)$ e $\mathbf{p} = (0.7, 0.2, 0.1)$.



- ▶ Consideramos as respostas de uma questão de uma pesquisa amostral com três repostas possíveis;
- ▶ Um total de $n = 1447$ adultos foram entrevistados para indicar a sua preferência, sendo que $n_1 = 727$ apoiaram George Bush, $n_2 = 583$ apoiaram Michael Dukakis e $n_3 = 137$ apoiaram outros candidatos ou não expressaram opinião;
- ▶ O objetivo desta análise é comparar a proporção de votos populacional entre Bush e Dukakis. Assim a estatística mais usual para realizar a comparação é $\theta = p_1 - p_2$, isto é, a diferença da proporção populacional entre os dois principais candidatos.

- Assumindo que as contagens n_1, n_2 e n_3 são observações da distribuição Multinomial com tamanho amostral n e respectivas probabilidades p_1, p_2 e p_3 . Então, a função de verossimilhança pode ser escrita na forma

$$L(\mathbf{p} \mid \mathbf{n}) \propto p_1^{n_1} p_2^{n_2} p_3^{n_3}. \quad (14)$$

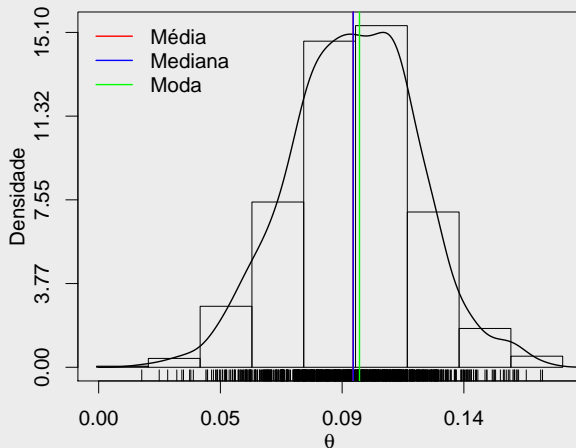
- ▶ Inferências a respeito de θ sera realizada sob as abordagens Clássica e Bayesiana.
- ▶ Os intervalos assintóticos para os parâmetros e para θ foram obtidos utilizando o erro padrão assintótico dado pela inversa da matriz de informação de Fisher observada.
- ▶ Sob a abordagem Bayesiana atribuímos distribuição a priori não informativa Dirichlet, isto é, $\pi(\mathbf{p}) \sim \mathcal{D}(1, 1, 1)$. Portanto como temos que $\pi(\mathbf{p} \mid \mathbf{n}) \sim \mathcal{D}(y_1 + 1, y_2 + 1, y_3 + 1)$.
- ▶ Valores pseudoaleatórios da distribuição Dirichlet foram gerados baseado no fato de que se W_1, W_2 e W_3 tem distribuição $\text{Gamma}(\alpha_i, 1), i = 1, 2, 3$ e $T = W_1 + W_2 + W_3$, então a distribuição das proporções $(W_1/T, W_2/T, W_3/T)$ tem distribuição $\mathcal{D}(\alpha_1, \alpha_2, \alpha_3)$.

Resumos inferências sob o enfoque Clássico e Bayesiano.

| Parâmetro | EMV (E.P.) | Média (D.P.) | I.C. 95% | H.P.D. 95% |
|-----------|-----------------|-----------------|------------------|------------------|
| p_1 | 0.5024 (0.0131) | 0.5020 (0.0130) | (0.4767, 0.5282) | (0.4763, 0.5264) |
| p_2 | 0.4029 (0.0129) | 0.4029 (0.0127) | (0.3776, 0.4282) | (0.3795, 0.4305) |
| p_3 | 0.0947 (0.0079) | 0.0951 (0.0077) | (0.0796, 0.1098) | (0.0801, 0.1100) |
| θ | 0.0995 (0.0248) | 0.0991 (0.0245) | (0.0508, 0.1483) | (0.0497, 0.1456) |

Votação eleitoral

Densidade da distribuição posteriori simulada de $\theta = p_1 - p_2$.



- ▶ Estudo sobre os intervalos de confiança simultâneos para os parâmetros da distribuição Multinomial:
 - ▶ Goodman, L. A., 1965. **On Simultaneous Confidence Intervals for Multinomial Proportions.** Technometrics 7, 247–254.
 - ▶ May, W. K., Johnson, W. D., 1997. **A SAS macro for constructing simultaneous confidence intervals for multinomial proportions.** Computer Methods and Programs in Biomedicine 53, 153–162.
- ▶ Inclusão de covariáveis:
 - ▶ High, R., 2013. **Models for Ordinal Response Data.** SAS Global Forum, Statistics and Data Analysis.